

Pablo Santiago Martínez Soler

Factores determinantes del precio del alojamiento en Airbnb: Río de Janeiro

Análisis exploratorio y modelado predictivo sobre datos de Inside Airbnb

Objetivo y datos

Este trabajo identifica qué características de un alojamiento explican su precio por noche en Río de Janeiro y evalúa en qué medida ese precio puede predecirse. La fuente son los listings públicos de Inside Airbnb: 44.542 publicaciones con precio válido y 90 variables originales. Tras la limpieza y el tratamiento de valores atípicos, el conjunto de análisis queda en 43.395 observaciones y 54 variables predictoras, más el texto de las descripciones.

Tratamiento de los datos

- **Imputación diferenciada según el patrón de ausencia.** Las variables de reseñas faltan de forma estructural —alojamientos que aún no recibieron reviews— y no al azar, por lo que se imputan por mediana junto con un indicador de presencia de reseñas. Las variables de tamaño se imputan por mediana dentro de cada tipo de habitación, ya que la mediana de dormitorios de un cuarto privado difiere de la de una casa entera.
- **Valores atípicos mediante filtro combinado.** Se excluyen las observaciones que superan el percentil 99 del precio o el percentil 99 del precio por persona. El segundo criterio resulta el más informativo: detecta alojamientos caros en relación a su capacidad, que un filtro de precio absoluto deja pasar. Se agregan filtros de coherencia entre capacidad declarada, camas y dormitorios.
- **Prevención de fuga de información.** Se excluye la variable de ingresos estimados, que se deriva del propio precio multiplicado por la ocupación, y el preprocesador se ajusta exclusivamente sobre el conjunto de entrenamiento.

Construcción de variables

Se incorporan dos variables geográficas que codifican explícitamente la estructura espacial del mercado: la distancia haversine a Copacabana, referencia del corredor de mayor valor inmobiliario de la ciudad, y un clustering espacial de veinticinco grupos sobre latitud y longitud, que separa submercados locales sin depender de los límites administrativos de barrio. El precio medio entre clusters varía de 361 a 879 reales.

El contenido textual de las publicaciones se incorpora mediante TF-IDF de cincuenta términos, integrado dentro del pipeline de preprocesamiento de modo que forma parte efectiva del modelo final y no de un análisis paralelo.

Resultados

Modelo	RMSE	MAE	R ²
Gradient Boosting (histogramas)	481.42	251.86	0.6252
Gradient Boosting	487.07	252.35	0.6163
Random Forest	516.48	263.45	0.5686
MCO	576.29	324.11	0.4629
LASSO	578.73	322.04	0.4584

El Gradient Boosting por histogramas alcanza el mejor desempeño, con un RMSE de 481.42 reales y un R² de 0.6252 sobre el conjunto de prueba. La brecha frente a los modelos lineales es sustancial y sistemática en las tres métricas, lo que indica que el precio depende de relaciones no lineales e interacciones entre tamaño, tipo de propiedad y ubicación que una especificación lineal no captura. Que LASSO no mejore a MCO refuerza esa lectura: el problema no es un exceso de variables irrelevantes, sino la forma funcional.

Determinantes del precio

Variable	Aumento del RMSE al permutar
bedrooms	110.9
bathrooms	60.1
accommodates	53.1
latitude	42.2
availability_365	15.5
availability_90	15.4
dist_km_copacabana	14.4
texto_tfidf (50 features)	12.7
room_type	11.9

La importancia se estima por permutación, midiendo cuánto se degrada el error al reordenar aleatoriamente cada variable. A diferencia de la importancia por impureza, este criterio no está sesgado hacia variables categóricas de alta cardinalidad.

- **El tamaño del alojamiento domina.** Dormitorios, baños y capacidad concentran la mayor parte del poder explicativo: permutar el número de dormitorios eleva el error en casi 111 reales, más del doble que la variable siguiente.
- **La ubicación constituye el segundo bloque.** La distancia a Copacabana entra entre las diez variables más relevantes pese a presentar una correlación lineal prácticamente nula con el precio

(-0.05). Río no tiene un único centro de valor sino varios polos dispersos, de modo que la relación precio-distancia no es monótona: el modelo no lineal la aprovecha, un enfoque lineal no podría. El caso ilustra el límite de seleccionar variables por correlación.

- **El texto de la descripción aporta señal medible**, con una importancia conjunta superior a la del tipo de habitación, lo que indica que el contenido de la publicación transmite información de precio ausente en las variables estructuradas.
- **La disponibilidad del calendario tiene peso propio**, sugiriendo que la política comercial del anfitrión y su ocupación efectiva están vinculadas al nivel de precio.

Consideración metodológica sobre la escala

Dada la asimetría del precio, es habitual modelar su logaritmo. Esa alternativa mejora el ajuste en escala logarítmica (R^2 de 0.573 frente a 0.463) y el error absoluto medio (272.91 frente a 324.11), pero empeora el error cuadrático medio en escala de precio real (608.19 frente a 576.29), incluso aplicando la corrección de sesgo de Duan sobre la transformación inversa. Ambos criterios optimizan objetivos distintos: el logaritmo penaliza errores relativos, mientras que el RMSE en escala original penaliza los errores absolutos grandes de la cola de precios altos. La elección de escala debe responder a qué error importa en el caso de uso concreto y no aplicarse por defecto.

Limitaciones

Con un R^2 de 0.63 permanece una porción relevante de la variación sin explicar, atribuible a factores no observables en los datos disponibles: la calidad de las fotografías de la publicación, el estado real de la propiedad, la estacionalidad de la demanda y los ajustes dinámicos de precio que aplican los anfitriones a lo largo del año.